

## **Feature Selection Generative AI Academy**

### **Part 4: Neural Networks — FSL**

João Pedro Silveira e Silva  
Bruno Lochins Grisci

# Conteúdo

- Introdução
- Conjuntos de dados
- Extensões para a Feature Selection Layer
- Experimentos e resultados
- Conclusão

# **Introdução**

---

# Feature weighting

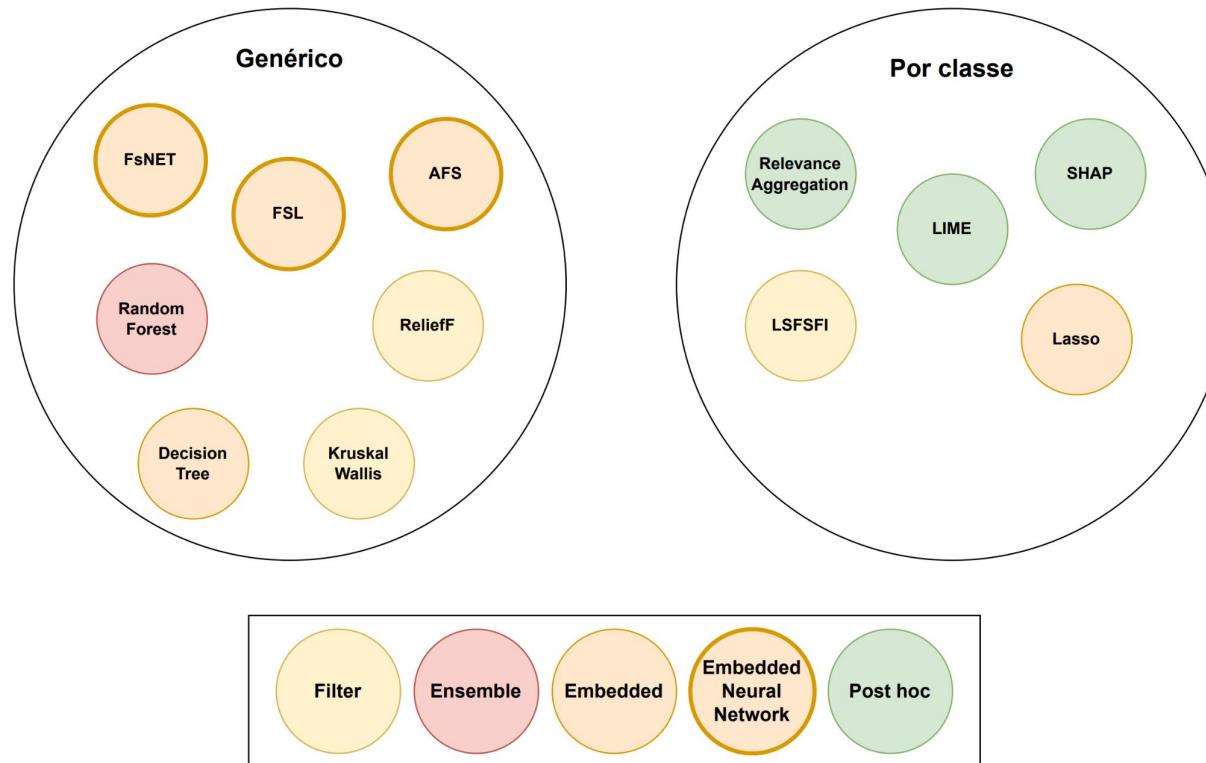
Genérico

Atributo	Peso
Comprimento da sépala	<b>0.65</b>
Largura da sépala	<b>0.15</b>
Comprimento da pétala	<b>0.10</b>
Largura da pétala	<b>0.10</b>

Por classe

Atributo	Peso Classe 0	Peso Classe 1	Peso Classe 2
Comprimento da sépala	<b>0.65</b>	<b>0.15</b>	<b>0.10</b>
Largura da sépala	<b>0.15</b>	<b>0.05</b>	<b>0.30</b>
Comprimento da pétala	<b>0.12</b>	<b>0.60</b>	<b>0.20</b>
Largura da pétala	<b>0.08</b>	<b>0.20</b>	<b>0.40</b>

# Feature weighting



# Maldição da dimensionalidade

Devido ao avanço de sensores, métodos de coleta e compartilhamento de dados, além de dispositivos de armazenamento e processamento cada vez mais potentes, a quantidade de informações disponíveis está crescendo a um ritmo exponencial.

Em diversos setores, a aquisição de uma grande quantidade de dados tornou-se comum, muitas vezes sem um plano claro de como serão analisados ou se serão realmente úteis. **Em muitas áreas, o número de atributos supera o número de elementos coletados.**

## Desafios:

- Ruído e irrelevância
- Espaço Exponencial
- Dificuldade para encontrar padrões
- Sobreajuste (overfitting)

**Apesar da adaptação lenta, a lei em diversos países vêm evoluindo para acompanhar com os avanços trazidos pela AI. Do ponto de vista jurídico, a interpretabilidade é fundamental para empresas que operam em diversos países.**

### **Brasil**

O Código de Defesa do Consumidor exige que bancos expliquem decisões tomadas com base em análises de crédito.

Além de proteger o consumidor contra o uso de seus dados ou o fornecimento de serviços de forma discriminatória, o que poderia ser causado por uma rede neural com viés.

### **Europa**

A Lei Geral de Proteção de Dados (GDPR), especificamente o artigo 22, garante o direito à explicaçāo de decisões tomadas por algoritmos de forma autônoma que possam impactar legalmente ou com impacto igualmente relevante a vida dos cidadãos. A falta de interpretabilidade pode inviabilizar o uso de redes neurais em diversas aplicações.

[Frazão; Oliva; Tepedino, 2019, Miragem, 2020, Bayamlioglu, 2022, Prince, 2023]

# **Conjuntos de dados**

---

# Dados sintéticos

Nome	Tipo dos atributos	Quantidade classes	Quantidade atributos	Relevantes	Relevantes por classe	Instâncias
XOR	Binário	2	50	2	2	500
SynthA	Numérico	3	100	30	30	3000
SynthB	Numérico	3	300	30	10	3000
SynthC	Numérico	3	300	30	15	3000

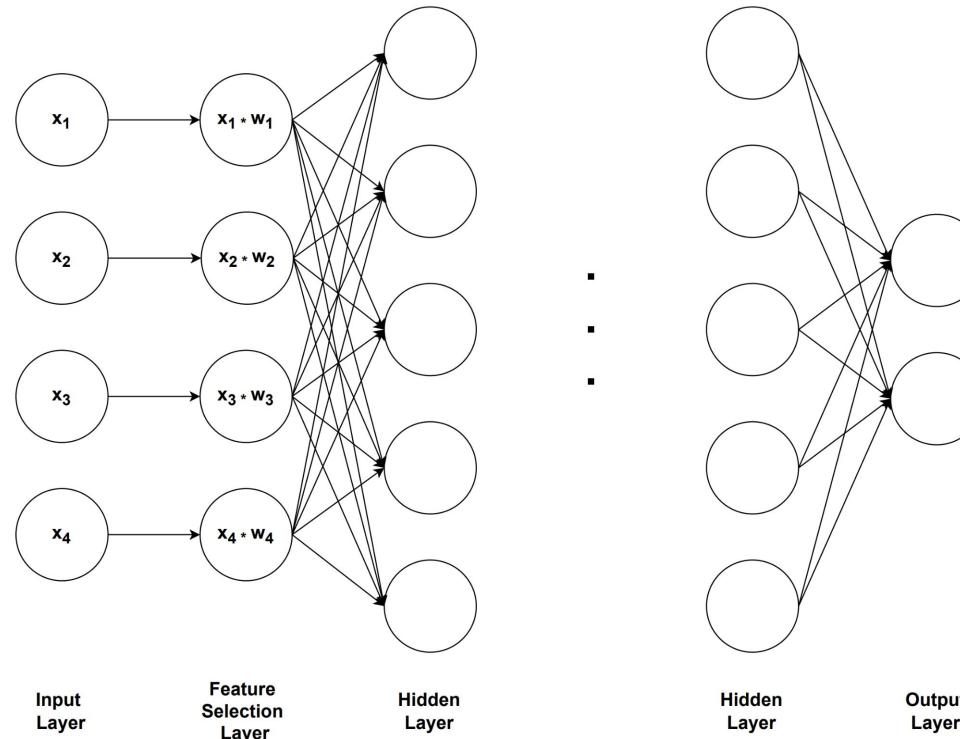
# CuMiDa

Nome	GSE	Tipo dos atributos	Quantidade classes	Quantidade atributos	Instâncias
Liver	22405	Numérico	2	22284	48
Prostate	6919_U95C	Numérico	2	12647	115
Colorectal	41657	Numérico	4	33468	86
Breast	45827	Numérico	6	54676	151

# Extensões para a Feature Selection Layer (FSL)

---

# FSL



# Listener

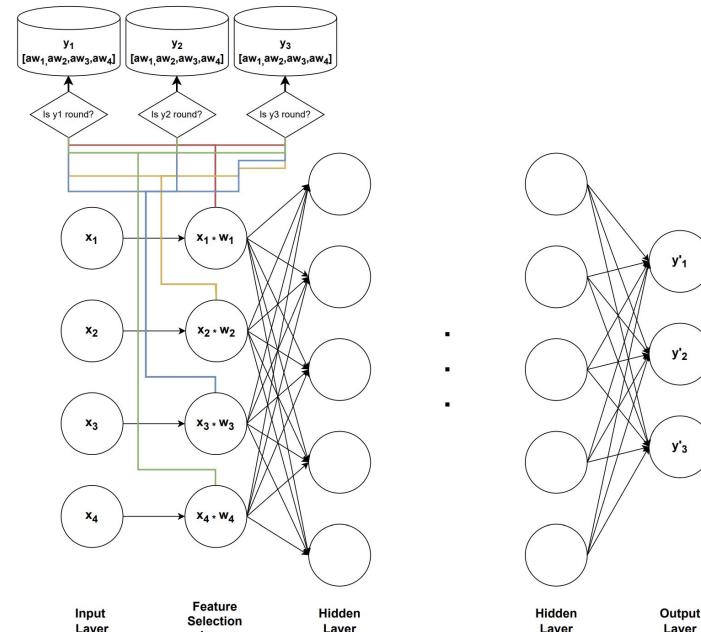
Adiciona um vetor de memória para cada classe que armazena as atualizações no peso destinado a cada atributo.

Objetivo:

- Entender como os pesos são atualizados para diferentes classes na implementação original do FSL.

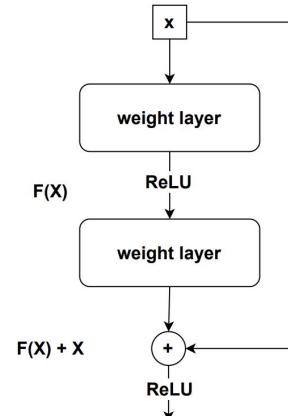
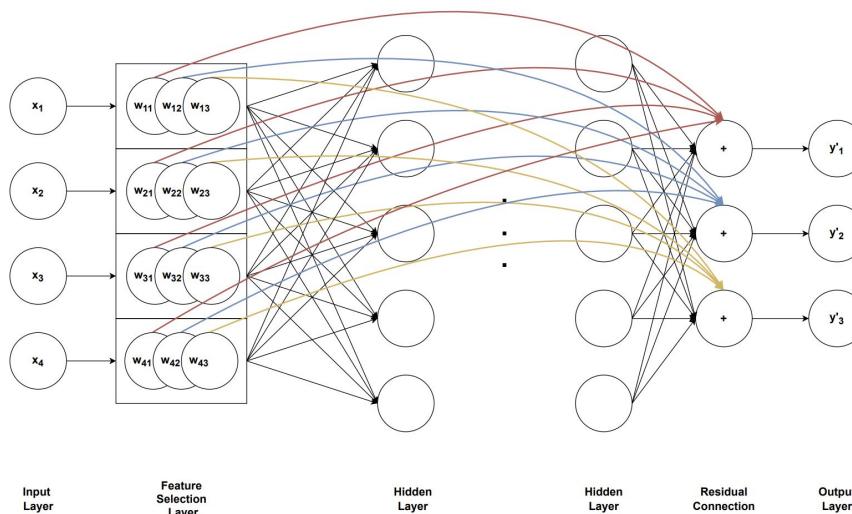
Limitação:

- Cada atualização de parâmetros durante o treinamento da rede neural precisa ser limitado a amostras de uma única classe.



# Residual

Utiliza múltiplas camadas de Feature Selection Layer, uma por classe, com conexões residuais as ligando a sua respectiva saída na rede neural.



$$x_i * \sum_{j=1}^l w_{ij}$$

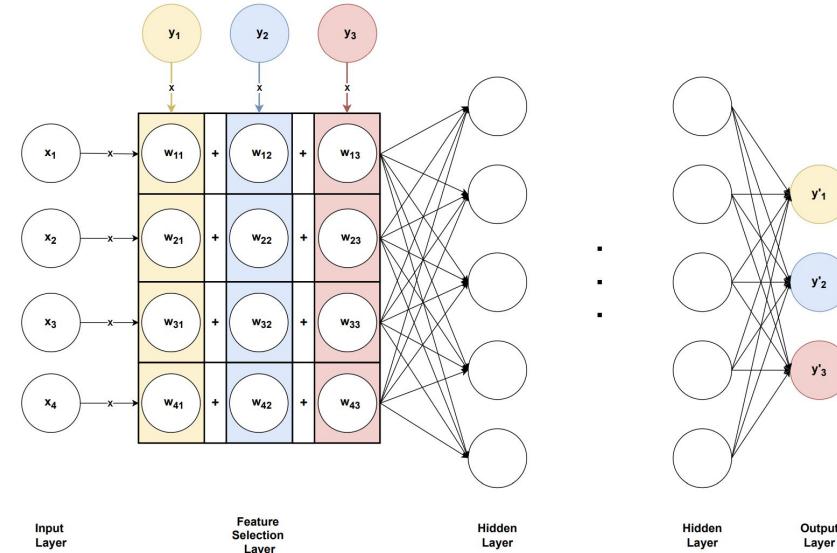
$$X * W_j + H_j$$

# Output Aware

Durante a fase de treinamento o vetor contendo as saídas esperadas deve ser informado a rede, ao qual será utilizado para selecionar quais pesos devem ser utilizados para cada amostra.

Limitação:

- Dado que a camada precisa conhecer a saída esperada para selecionar quais pesos devem ser utilizados durante o treinamento, ao final do processo de aprendizado os pesos específicos para cada classe precisam ser agregados em um único valor.

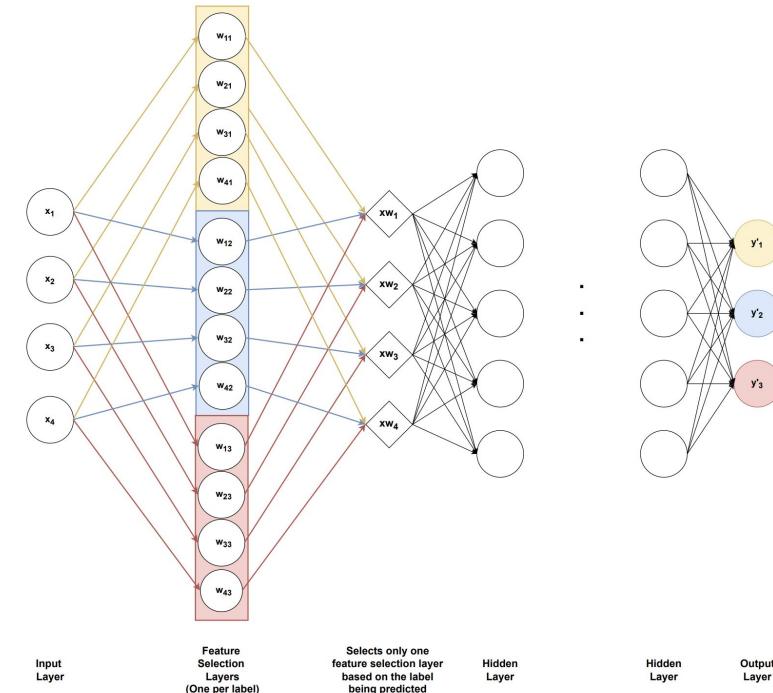


# Multiple Feature Selection Layer

Adiciona um vetor de pesos de atributos para cada classe e utiliza-os de forma individual para calcular a “probabilidade” de cada classe.

Limitação:

- Aumento do tempo para a predição uma vez que percorre a rede neural uma vez para cada classe.
- Aumento do tamanho do modelo e consumo de memória.



# Experimentos e resultados

---

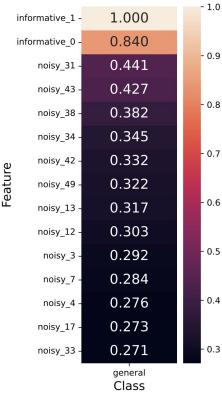
—

# Comparação entre as extensões propostas

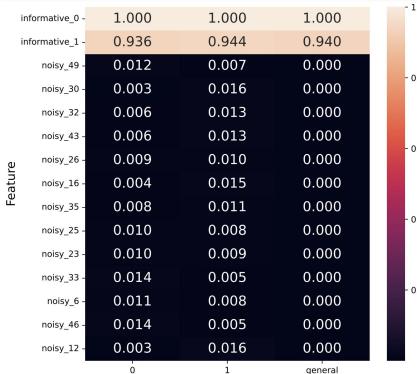
—

# Heatmap - XOR

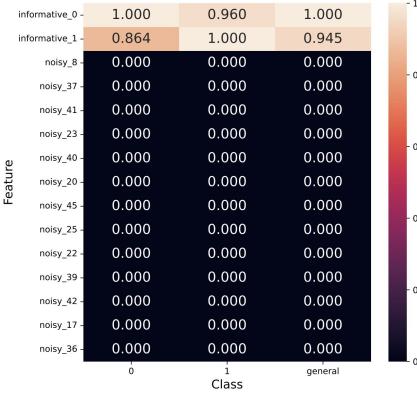
FSL



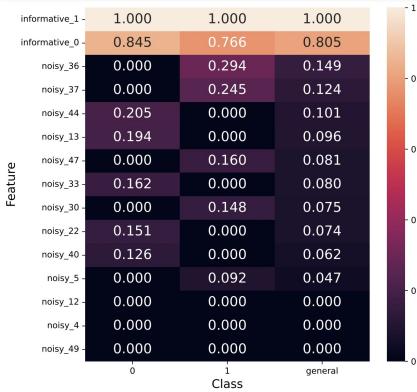
Listener



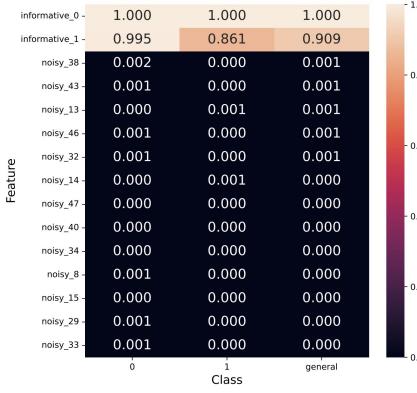
Output Aware



Residual



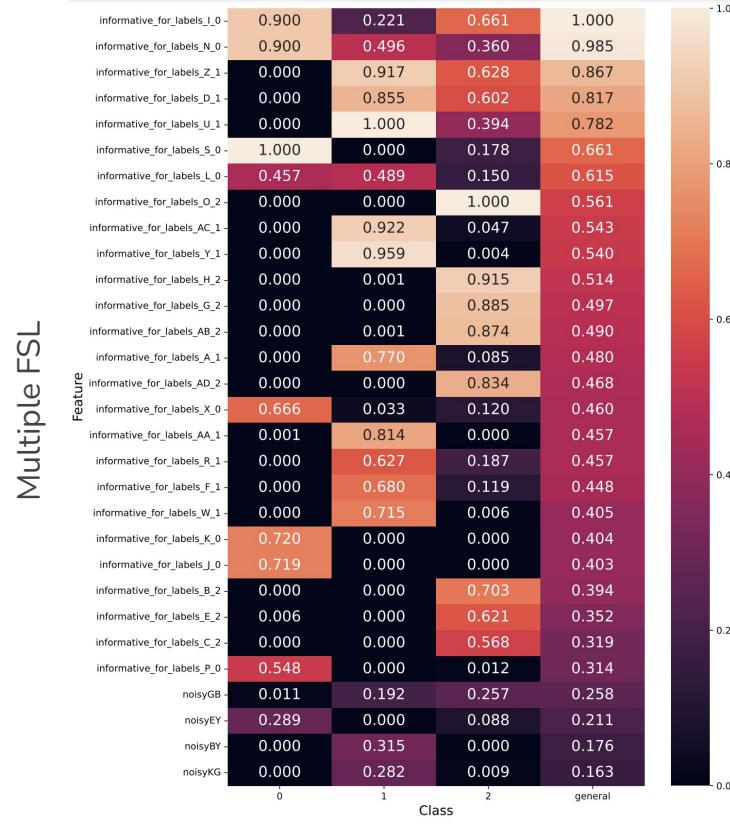
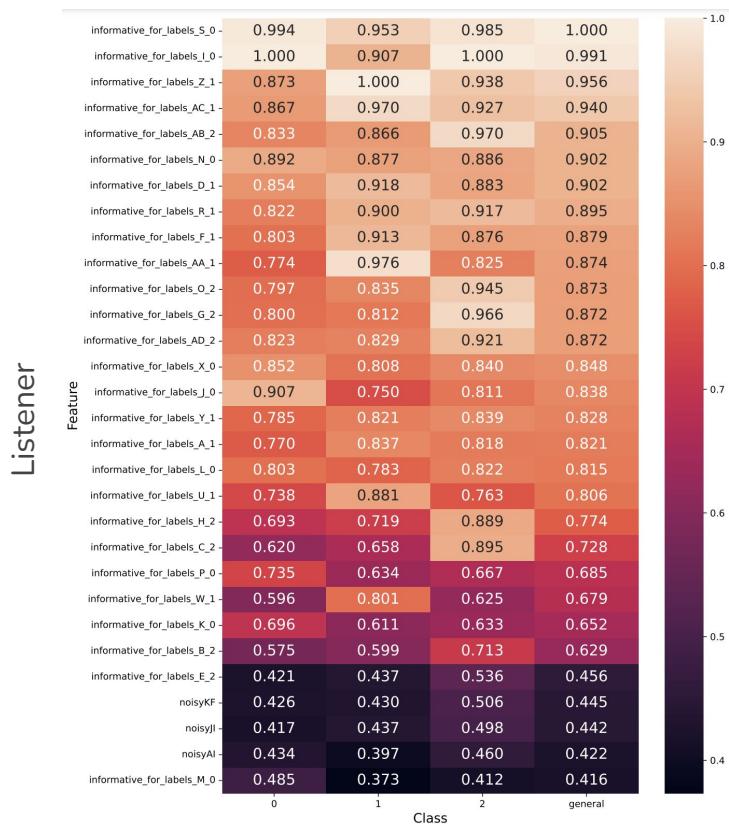
Multiple FSL



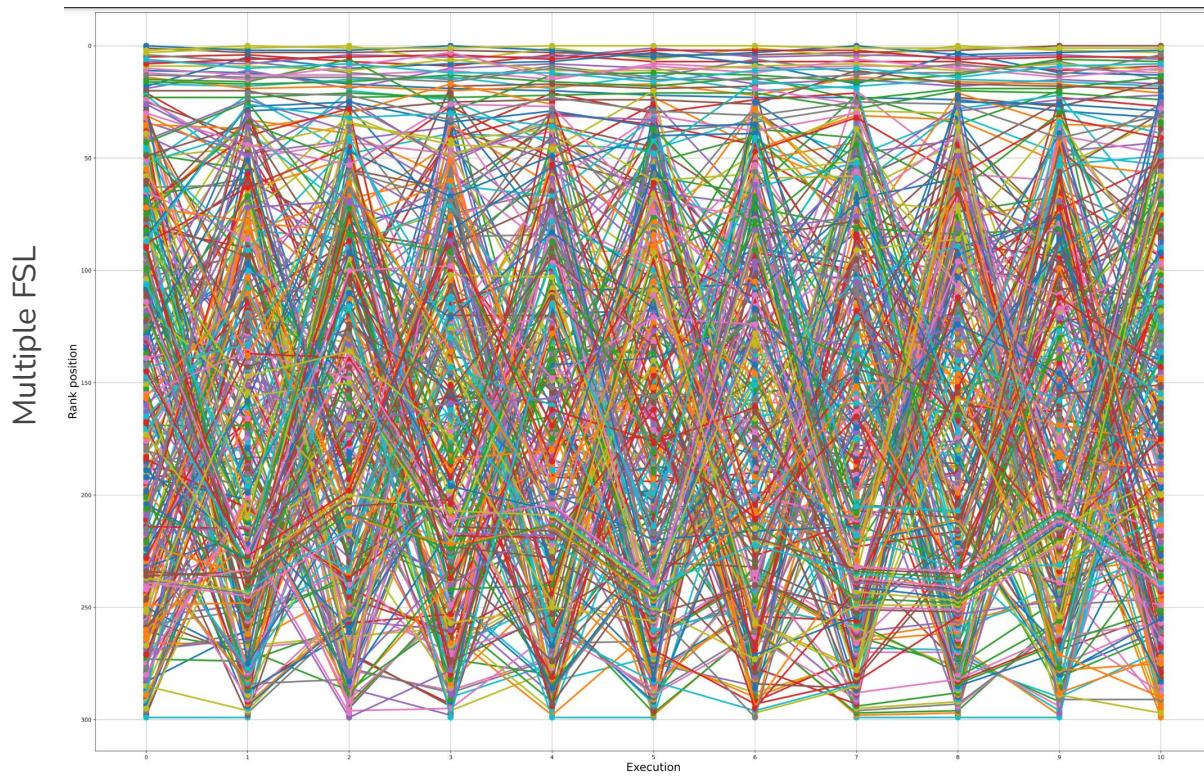
# Tempo de execução - XOR

Algorithm	Execution time (s)
FSL	$19.650 \pm 0.588$
Listener	$24.199 \pm 1.308$
Residual	$22.017 \pm 0.045$
Output Aware	$22.415 \pm 1.356$
Multiple FSL	$31.797 \pm 2.075$

# Heatmap - SynthB



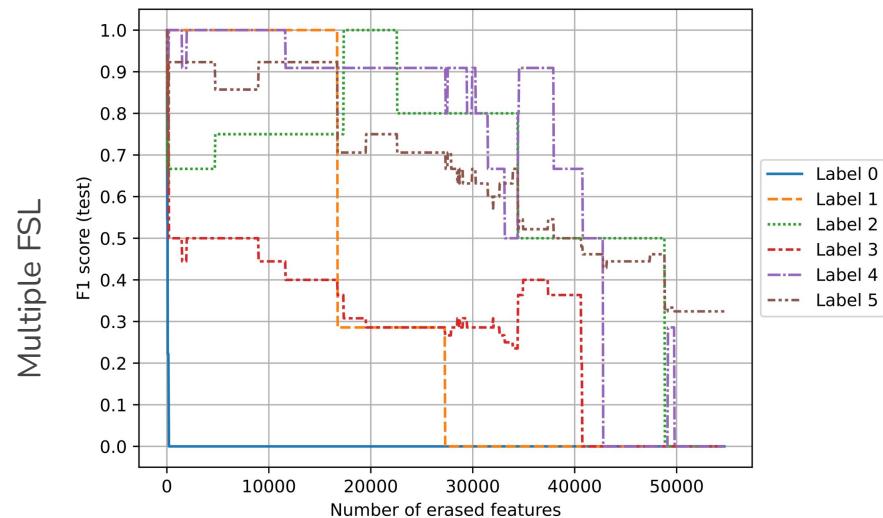
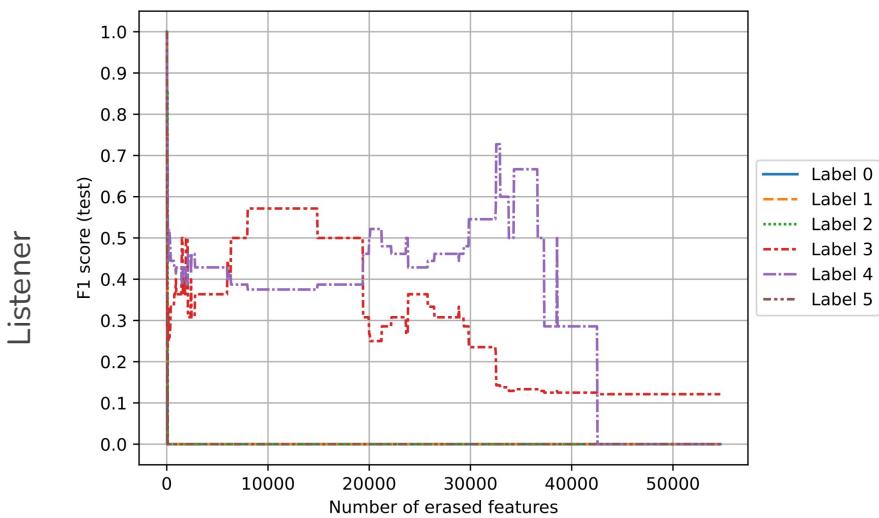
## Estabilidade entre atributos relevantes e ruidosos - SynthC



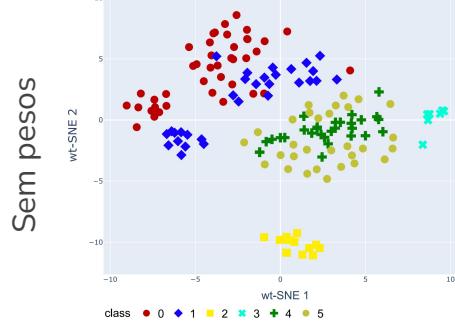
## Comparação entre a performance de predição - Breast

Algoritmo	Basal	HER	cell_line	normal	luminal_A	luminal_B
FSL	.983±.029	.965±.049	<b>1.0±.0</b>	<b>1.0±.0</b>	<b>.986±.030</b>	<b>.967±.044</b>
Listener	.989±.023	.969±.041	<b>1.0±.0</b>	<b>1.0±.0</b>	.980±.045	.957±.064
Residual	.840±.104	.403±.283	.809±.207	.697±.437	.818±.256	.536±.110
Output Aware	.906±.185	.705±.246	.890±.173	.928±.227	.867±.278	.715±.155
Multiple FSL	<b>.995±.017</b>	<b>.985±.033</b>	<b>1.0±.0</b>	<b>1.0±.0</b>	.979±.034	.965±.063

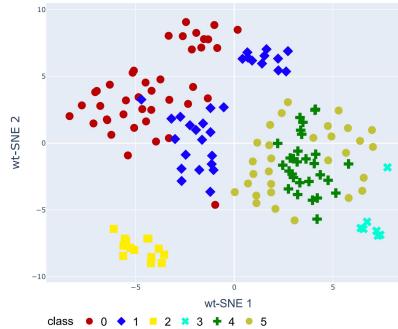
## Supressão de atributos para classe Basal (linha azul) - Breast



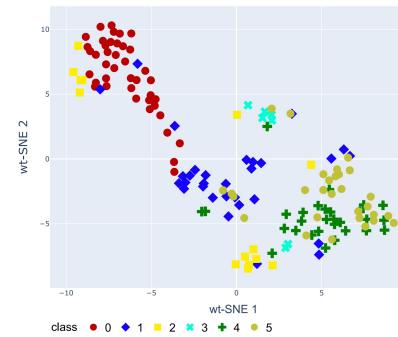
# Weighted t-SNE para classe Basal (vermelho) - Breast



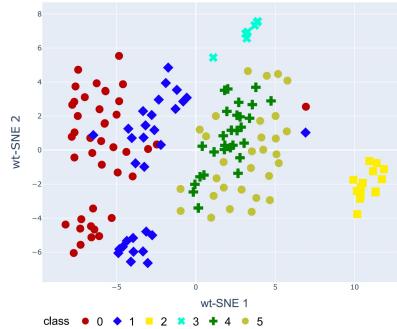
Listener



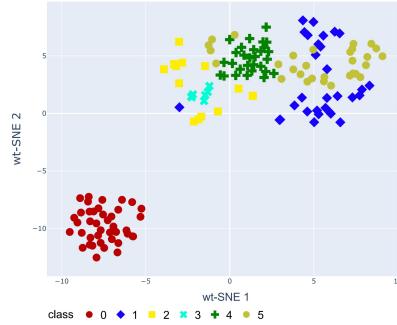
Output Aware



Residual



Multiple FSL



# Resultados

- Todas as extensões foram capazes de definir pesos mais altos para atributos relevantes
- Residual e Output Aware demonstraram um impacto negativo na capacidade de predição do modelo
- Apenas o Output Aware e o Multiple FSL foram capazes de atribuir diferentes pesos para os atributos relacionados a sua relevância para cada classe.
- **Mesmo demonstrando um aumento no tempo de treinamento e no tamanho do modelo, o Multiple FSL teve os melhores resultados gerais entre as extensões propostas.**

# Comparação do Multiple FSL com algoritmos existentes

Algoritmos:

- Lasso
- LIME
- DeepSHAP
- Multiple FSL

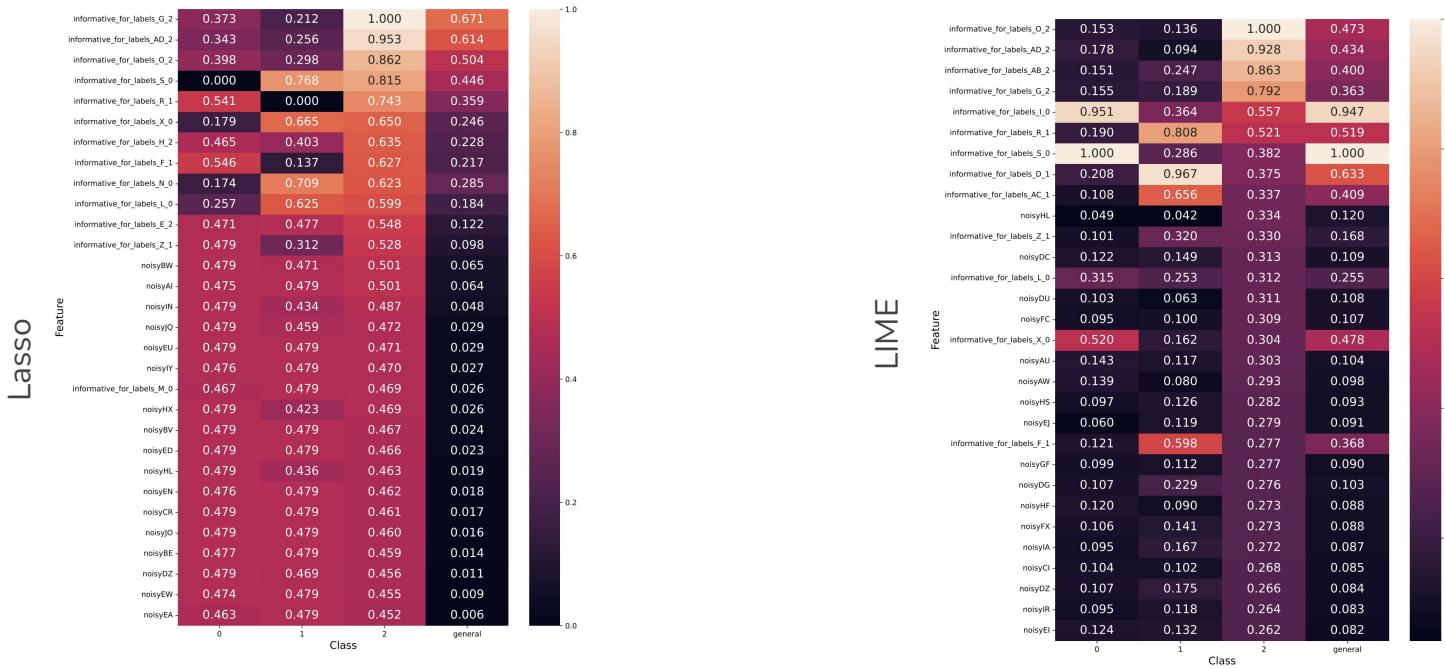
—

# Classificação multiclasse com conjuntos de dados sintéticos

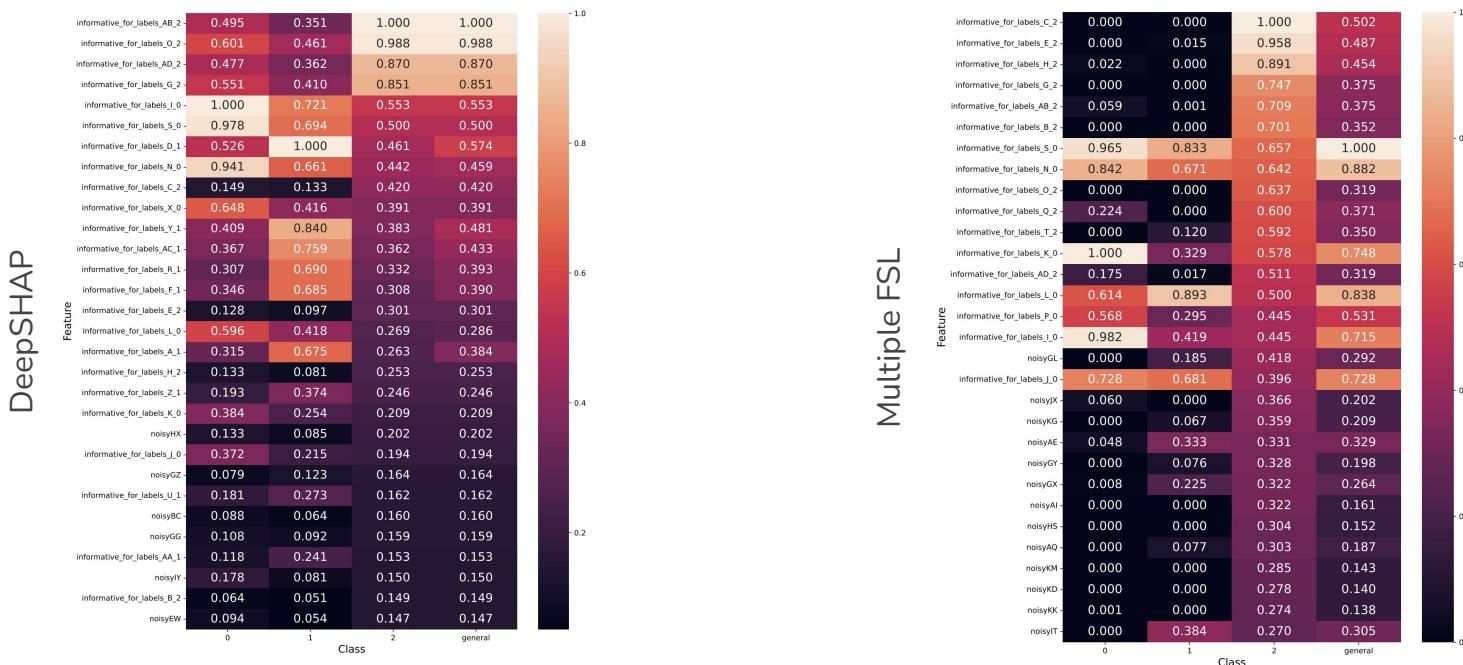
—

Comparação entre Multiple FSL e métodos  
existentes de *feature weighting*

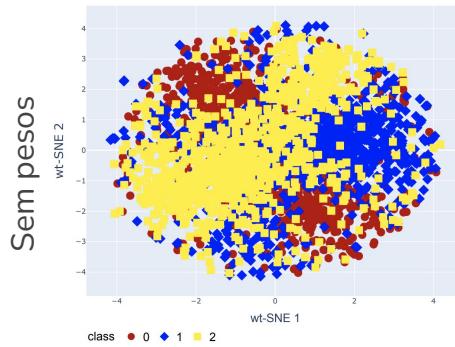
## Heatmap ordenado pelos pesos da classe 2 - SynthB



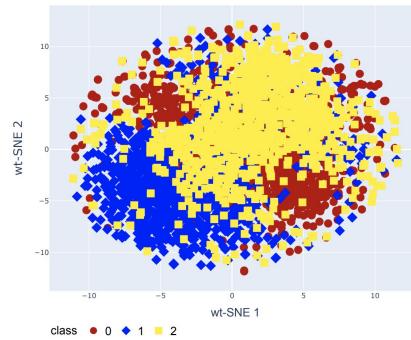
## Heatmap ordenado pelos pesos da classe 2 - SynthB



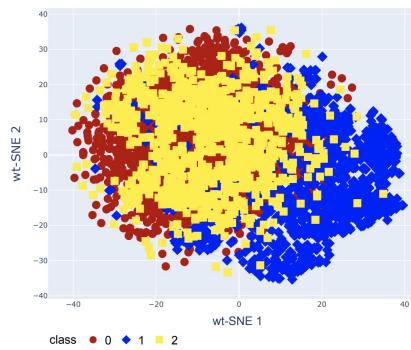
# Weighted t-SNE para classe 1 (azul) - SynthB



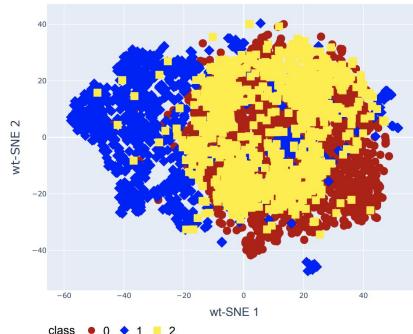
Lasso



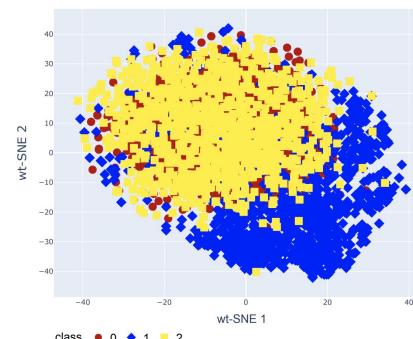
LIME



DeepSHAP



Multiple FSL





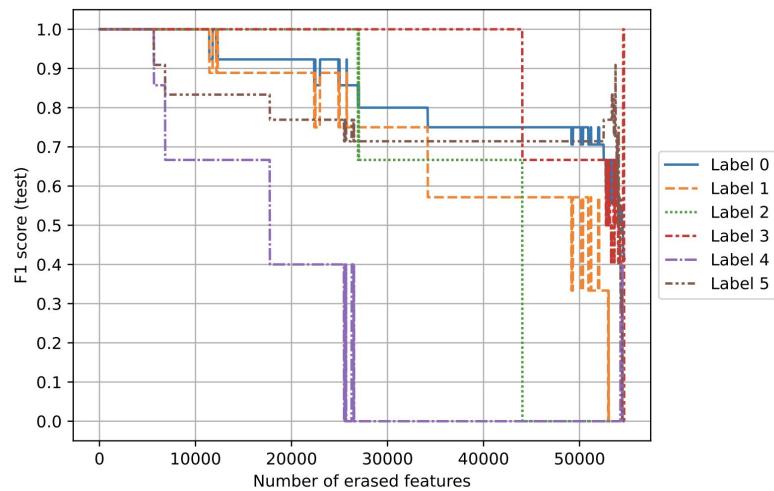
# **Classificação multiclasse com Breast**



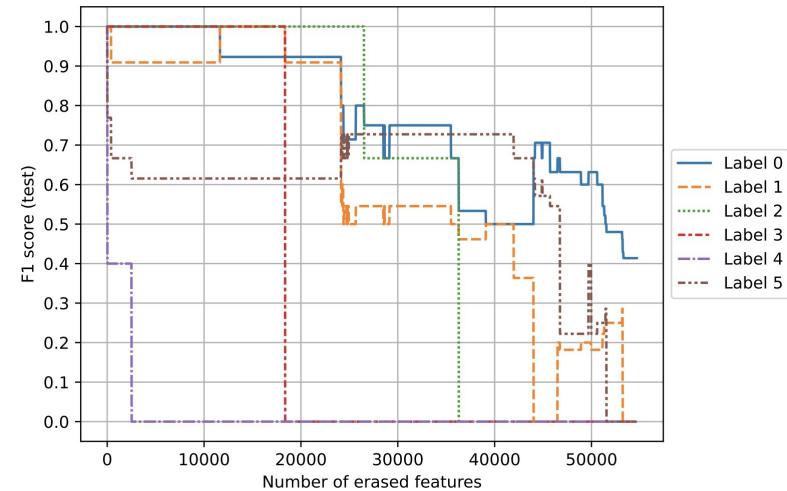
Comparação entre Multiple FSL e métodos  
existentes de *feature weighting*

## Supressão de atributos para classe luminal\_A (linha roxa) - Breast

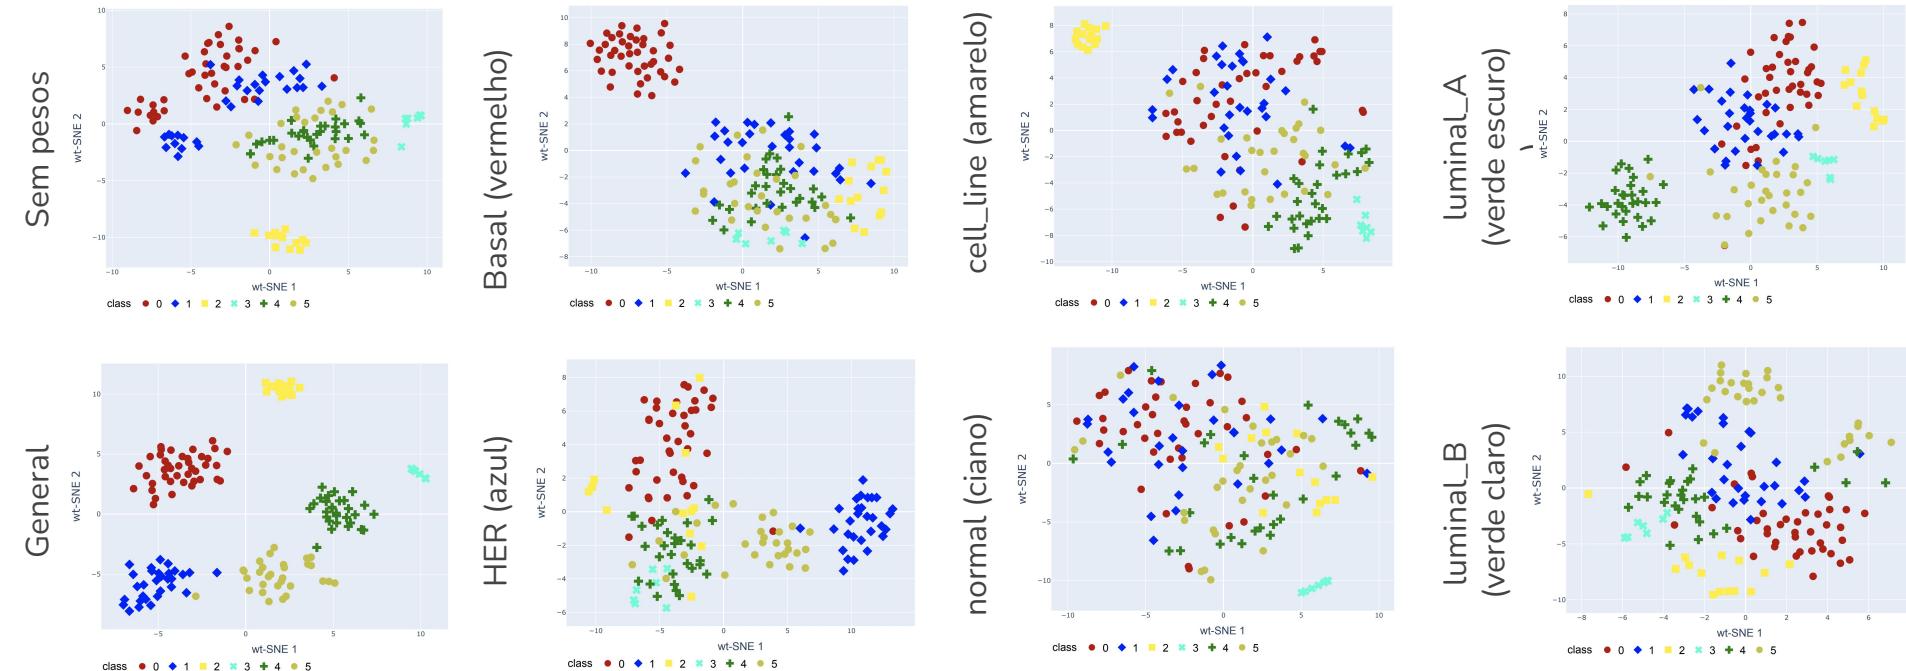
DeepSHAP



Multiple FSL



# Multiple FSL weighted t-SNE - Breast



# Conclusão

---

## Contribuições

“É possível estender uma Feature Selection Layer (FSL) para aprender a relevância de atributos específica por classe?”

- Proposta de quatro extensões para a Feature Selection Layer com o objetivo de gerar pesos específicos por classe.
- Seleção do Multiple FSL como o método mais promissor através de experimentação extensiva usando diferentes técnicas como supressão de atributos, weighted t-SNE, conjuntos de dados sintéticos, heatmaps, performance de predição e avaliação de estabilidade.

“Como a adaptação se compara aos métodos existentes?”

- Comparação do Multiple FSL com métodos existentes para demonstrar sua competitividade quando aplicado para gerar pesos de relevância genéricos e sua superioridade para gerar pesos de relevância específicos por classe.

MURDOCH, W. J.; SINGH, C.; KUMBIER, K.; ABBASI-ASL, R.; YU, B. Definitions, methods, and applications in interpretable machine learning. **Proceedings of the National Academy of Sciences**, National Acad Sciences, v. 116, n. 44, p. 22071–22080, 2019.

MOLNAR, C.; CASALICCHIO, G.; BISCHL, B. Interpretable machine learning—a brief history, state-of-the-art and challenges. In: SPRINGER. **Joint European conference on machine learning and knowledge discovery in databases**. [S.l.], 2020. p. 417–431.

BAYAMLIOGLU, E. The right to contest automated decisions under the general data protection regulation: Beyond the so-called “right to explanation”. **Regulation & Governance**, v. 16, n. 4, p. 1058–1078, 2022. Available from Internet: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/rego.12391>>.

MIRAGEM, B. Discriminação injusta e o direito do consumidor. **O direito do consumidor no mundo em transformação: em comemoração aos 30 anos do Código de defesa do consumidor**, v. 30, p. 203–206, 2020. Available from Internet: <<https://bdjur.stj.jus.br/jspui/handle/2011/153120>>

FRAZÃO, A.; OLIVA, M. D.; TEPEDINO, G. **Lei Geral de Proteção de Dados Pessoais e suas repercussões no direito brasileiro.** [S.l.]: Thomson Reuters Brasil, 2019.

PRINCE, S. J. **Understanding Deep Learning.** Paris, France: The MIT Press, 2023. 541 p. ISBN 9780262048644. Available from Internet: <<https://mitpress.mit.edu/9780262048644/understanding-deep-learning/>>